

Projet de Statistiques 1

Copules et modélisation de la dépendance entre marchés financiers

TAHA EL OUAHABI & LOIC DIRIDOLLOU

Proposé par Alexis Derumigny

1 Introduction : autour du théorème de Sklar

- 1 Soit $C_{1,2} = F_{1,2}(F_1^{-1}(u_1), F_2^{-1}(u_2))$
 $\forall u_1, u_2 \in [0, 1] \implies \exists (x, y) \in (S_1, S_2), u_1 = F_1(x) u_2 = F_2(y)$
 Ainsi $\forall u_1, u_2,$

$$\begin{aligned} C_{1,2}(u_1, u_2) &= F_{1,2}(F_1^{-1}(F_1(x)), F_2^{-1}(F_2(y))) \\ &= F_{1,2}(x, y) \end{aligned}$$

On a bien que $C_{1,2}(F_1, F_2) = F_{1,2}$

- 2 [a] Soit $U_1 = F_1(X_1)$

$$\begin{aligned} \mathbb{P}(U_1 < t) &= \mathbb{P}(F_1(X_1) < t) \\ &= \mathbb{P}(X_1 < F_1^{-1}(t)) \\ &= F_1(F_1^{-1}(t)) \\ &= t \end{aligned}$$

D'où $X_1 \sim \mathcal{U}([0, 1])$

[b]

$$\begin{aligned} C_{1,2}(u_1, u_2) &= \mathbb{P}(X_1 < u_1, X_2 < u_2) \\ &= \mathbb{P}(U_1 < u_1, U_2 < u_2) \end{aligned}$$

Par les propriétés de la loi uniforme, on a que $\mathbb{P}(U_1 < u_1, U_2 < u_2) \rightarrow 0$ quand $u_1, u_2 \rightarrow 0$
 On applique le même raisonnement pour la limite en 1 et on a bien le résultat attendu.

[c] D'après le résultat ci-dessus, on a que $C_{1,2}$ est bien une fonction de répartition. De plus avec les propriétés de U_1 et U_2 on a que $C_{1,2}(U_1, U_2) = F_{1,2}$ est bien la fonction de répartition du couple (U_1, U_2) uniforme sur $[0, 1]^2$, ce qui provient notamment du fait que la densité se renormalise forcément à 1 en somme sur l'ensemble de définition.

[d] En utilisant à la fois la question a et la question c, on a bien que les marges de $C_{1,2}$ sont uniformes, de plus par propriétés de F_1 et F_2 , toutes deux fonctions de répartition, on a bien la dérivabilité en chacun des arguments.

On en déduit donc que $C_{1,2} \in \mathcal{C}$, d'où $C_{1,2}$ est une copule.

- 3 D'après la première question, on a bien que Γ est surjective.

On sait de plus d'après la question 2.c) que $C_{1,2}$ est la fonction de répartition du vecteur.

De cette façon, il est aisé de retrouver la première composante du vecteur qui est F_1 , on retrouve de même F_2 .

Il vient immédiatement la surjectivité de la fonction et le résultat attendu.

2 Estimation des copules gaussiennes

1 On a par définition :

$$\begin{aligned}
 C_{1,2}(u_1, u_2) &= F_{1,2}(F_1^{-1}(u_1), F_2^{-1}(u_2)) \\
 &= P(X_1 \leq F_1^{-1}(u_1), X_1 \leq F_2^{-1}(u_2)) \\
 C_{1,2}(u_1, u_2) &= F_{1,2}\left(\frac{X_1 - \mu_1}{\sigma_1} \leq \frac{F_1^{-1}(u_1) - \mu_1}{\sigma_1}, \frac{X_2 - \mu_2}{\sigma_2} \leq \frac{F_2^{-1}(u_2) - \mu_2}{\sigma_2}\right) \\
 &= \Phi_{1,2}\left(\frac{F_1^{-1}(u_1) - \mu_1}{\sigma_1}, \frac{F_2^{-1}(u_2) - \mu_2}{\sigma_2}\right)
 \end{aligned}$$

Il ne reste plus qu'à montrer que $\frac{F_1^{-1}(u_1) - \mu_1}{\sigma_1} = \Phi_1(u_1)$.

$$\begin{aligned}
 F_1(\sigma_1 \Phi_1(u_1) + \mu_1) &= \mathbb{P}(X_1 \leq \sigma_1 \Phi_1(u_1) + \mu_1) \\
 &= \mathbb{P}\left(\frac{F_1^{-1}(u_1) - \mu_1}{\sigma_1} \leq \Phi_1(u_1)\right) \\
 &= \Phi_1(\Phi_1^{-1}(u_1)) \\
 &= u_1, \text{ d'où le résultat}
 \end{aligned}$$

De la même façon on a l'égalité pour la seconde composante. Alors $C_{1,2}(u_1, u_2) = F_{1,2}(F_1^{-1}(u_1), F_2^{-1}(u_2))$ ne dépend que de ρ .

2 [a] V_{i1} et V_{i2} sont définies comme U_1 et U_2 ainsi on a l'égalité en loi $\forall i$.

De plus d'après la partie I, 2.c C_ρ est la fonction de distribution du couple (U_1, U_2) , elle l'est donc aussi pour $(V_{i,1}, V_{i,2})$.

[b] Soit $F_{i1,i2}$ la fonction de répartition de (X_{i1}, X_{i2}) .

On a :

$$\begin{aligned}
 F_{i1,i2}(x_1, x_2) &= \mathbb{P}(\Phi_1^{-1}(V_{i1}) \leq x_1, \Phi_2^{-1}(V_{i2}) \leq x_2) \\
 &= C_\rho(\Phi_1(x_1), \Phi_2(x_2))
 \end{aligned}$$

alors :

$$\begin{aligned}
 F_{i1,i2}(x_1, x_2) &= C_\rho(F_1(x_1), F_2(x_2)) \\
 &= C_{1,2}(F_1(x_1), F_2(x_2)) \\
 &= F_{1,2}(x_1, x_2)
 \end{aligned}$$

3 [a] $\hat{\rho} = \arg \max_{\rho} \sum_{i=1}^n \log(c_\rho(G_1(Y_{i1}), G_2(Y_{i2})))$

Mais on a d'après 2) :

$$(G_1(Y_{i1}), G_2(Y_{i2})) = (u_1, u_2) = (\Phi(X_{i,1}), \Phi(X_{i,2}))$$

D'où on a :

$$\forall \rho, \sum_{i=1}^n \log(c_\rho(G_1(Y_{i1}), G_2(Y_{i2}))) = \sum_{i=1}^n \log(c_\rho(\Phi(X_{i1}), \Phi(X_{i2})))$$

[b] Par définition de c_ρ , on a :

$$\begin{aligned}
c_\rho &= \frac{\partial^2 C_\rho}{\partial x_1 \partial x_2} \\
f_{1,2}(X_1, x_2) &= \frac{\partial^2 F_{1,2}(x_1, x_2)}{\partial x_1 \partial x_2} \\
&= \frac{\partial^2 F_{1,2}(\Phi^{-1}(\Phi(x_1)), \Phi^{-1}(\Phi(x_2)))}{\partial x_1 \partial x_2} \\
&= \frac{\partial^2 C_\rho(\Phi(x_1), \Phi(x_2))}{\partial x_1 \partial x_2} \\
&= \frac{\partial}{\partial x_1} \frac{\partial C_\rho(\Phi(x_1), \Phi(x_2))}{\partial x_2} \\
&= \frac{\partial}{\partial x_1} \frac{\partial \Phi(x_2)}{\partial x_2} C_{\rho 2}(\Phi(x_1), \Phi(x_2)) \\
&= \phi(x_2) \frac{\partial}{\partial x_1} C_{\rho 2}(\Phi(x_1), \Phi(x_2)) \\
&= \phi(x_2) \phi(x_1) C_\rho(\Phi(x_1), \Phi(x_2))
\end{aligned}$$

[c] On a d'après la question précédente et la définition de $\hat{\rho}$ Alors

$$\begin{aligned}
\hat{\rho} &= \arg \max_{\rho} \left(\sum_{i=1}^n \log(\phi(x_1)\phi(x_2)) + \sum_{i=1}^n \log(f_{1,2}(x_1, x_2)) \right) \\
&= \arg \max_{\rho} \left(\sum_{i=1}^n \log(f_{1,2}(x_1, x_2)) + cste(\rho) \right)
\end{aligned}$$

Or $cste(\rho) = \sum_{i=1}^n \log(\phi(x_1)\phi(x_2))$ qui ne dépend pas de ρ .

Alors, la maximisation de $\sum_{i=1}^n \log(f_{1,2}(x_1, x_2))$ coïncide avec $\hat{\rho}$.

$\hat{\rho}$ est alors un EMV.

[d] $\hat{\rho}$ a alors les propriétés asymptotiques usuelles d'une MLE sous les conditions de régularités (qui sont vérifiées dans le cadre d'un vecteur gaussien) :

- converge en probabilité

- efficace asymptotiquement $\sqrt{n}(\hat{\rho} - \rho) \rightarrow \mathcal{N}(0, I^{-1}(\rho))$ donc de variance minimum pour la borne FDCR avec $I_1(\rho)$ l'information de Fischer pour le paramètre ρ .

3 Application à des données simulées

```
1 library(ggplot2)
```

```
x <- rnorm(500, 0, 1)
```

```
z <- rnorm(500, 0, 1)
```

```
m1 <- cbind(x,z)
```

```
m2 <- scale(m1)
```

```
c1 <- chol(var(m2))
```

```
m3 <- m2 %*% solve(c1)
```

```

# la matrice de corr?lation que tu souhaites obtenir
cor1 <- matrix(c(1,0.8,0.8,1),2)

m4 <- m3 %*% chol(cor1)
m5 <- sweep( m4, 2, attr(m2, 'scaled:scale'), '*' )
m5 <- sweep( m5, 2, attr(m2, 'scaled:center'), '+' )

cor(m5) # coefficient de corr?lation

x1 <- m5[,1]
x2 <- m5[,2]

coef(lm(x2 ~ x1)) #pour avoir les coefficients de  $x_2 = a + bx_1$ 

qplot(x1,x2,xlab="X1",ylab="X2") + geom_abline(intercept = 0.08506075, slope = 0.82355114,

v1 <- pnorm(x1,0,1)
v2 <- pnorm(x2,0,1)

coef(lm(v2 ~ v1)) #pour avoir les coefficients de  $v_2 = a + b.v_1$ 

qplot(v1,v2,xlab="V1",ylab="V2") + geom_abline(intercept = 0.1221782, slope =
0.8102443, color = 'red')
# les points obtenus sont plus dispers?s que pour les points (X1,X2) mais on
a quasiment la meme correlation.

qlapl <- function(x) {
#y <- 1:500
for (i in 1:length(x)){
if (x[i]<=1/2) {y <- log(2*x)}
else {y <- -log(2*(1-x))}
}
return(y)
}

y1 <- qcauchy(v1,0,1)
y2 <- qlapl(v2)


#nuage des points
qplot(y1, y2, colour = 'red')
#vu la forme du nuage de points on remarque que la variable y1 ne 'varie' pas
lorsque y2 varie, on en deduit qu'il n y a pas d'interactions entre les deux
variables, d'o? correlation nulle
lm(y2~y1)
#ceci est aussi confirme par le faible coefficient de correlation (de pearson)
qu'on obtient alors un coefficient de correlation de l'ordre de 1.645729e-05 qui
est tres faible,

```


#theoriquement, les variables V_1 et V_2 sont corréles, du coup on peut rien dire concernant la corrélation entre les deux lorsque on compose V_1 et V_2 par les fonctions G_1 inverse et G_2 inverse!.

- 2 À la vue du nuage de points, les deux variables sont non corrélées : Y_1 ne "varie" pas lorsque Y_2 varie. Il n'y a donc pas d'interactions entre les deux variables (elles sont très faibles).

Théoriquement on devrait avoir la même dépendance qu'entre X_1 et X_2 .



(a) Nuage de points avec V_1 , V_2



(b) Nuage de points avec X_1 , X_2




FIGURE 2 – Picture 2

4 Application à des données de marchés financiers

- (a) cf. code en fin de document
- (b) À partir du nuage des points, on peut dire que les deux variables sont très faiblement corrélées au sens de Pearson.
- (c) Le paramètre obtenu ρ est 0.63, très proche de la valeur de la regression de V_2 en V_1 .

- (d) Les lignes de niveaux pour la densité de la copule estimée sur l'échantillon (V_1, V_2) sont très proches en forme du contour de la densité d'un couple gaussien de corrélation $\rho = 0.63$. On peut conclure que c'est une bonne approximation de la copule gaussienne.

```
data1 = read.csv('/Users/taha/Desktop/EDU/Stat1 Projet/~DJI.csv')
data2 = read.csv('/Users/taha/Desktop/EDU/Stat1 Projet/~FCHI.csv')
#on fait un merge sur date pour que les valeurs NULL apparaissent
data = merge(data1, data2, by = 'Date')
library(dplyr)
data = data%>%
filter(Open.y != 'null')
# pour Dow jones on code la variation relative
data$var_cac <- NA
data$var_cac[1] = 0
for (i in (2:length(data$Open.x)))
{data$var_cac[i] = (data$Open.x[i]-data$Open.x[i-1])/data$Open.x[i-1]}

#la var pour CAC 40

data$var_cac1 <- NA
data$var_cac1[1] = 0
for (j in (2:length(data$Open.y)))
{data$var_cac1[j] = (as.double(data$Open.y[j])-as.double(data$Open.y[j-1]))/as.
double(data$Open.y[j-1])}

qplot(data$var_cac1, data$var_cac, xlab="Y1",ylab="Y2")

lm(data$var_cac~data$var_cac1)
# a partir du nuage des points, on peut dire que les deux variables sont très
faiblement correles au sens de pearson

#Fonction de repartition

dis1 = ecdf(data$var_cac1)
dis2 = ecdf(data$var_cac)
V1 = dis1(data$var_cac1)
V2 = dis2(data$var_cac)

qplot(V1,V2) + geom_abline(intercept = 0.1939, slope = 0.1939, color = 'red')
lm(V1~V2)
#la correlation entre V1 et V2 (au sens de pearson) est beaucoup plus importantes
que pour Y1 et Y2

library(VineCopula)
```

```

ro <- BiCopEst(V1, V2, family = 1, method = "mle")
summary(ro)

# pour le parametre ro = 0.63 on ecrit:
plot <- BiCop(family = 1, par = 0.63) #on simule une Copule gaussienne
plot(plot)

contour(plot)

max(V1)
max(V2)
min(V1)
min(V2)



# on une valeur de V1 ou de egale 1


for (i in 1:length(V1))
if (V1[i] == 1) print(i) # pour i = 2001 on V1 = 1

# on elimine ces observations parce que dans le cas d'une distribution normale, X a des
valeurs infinies car  $F(X) = 1$ 
fus = cbind(V1,V2)
U = subset(fus, V1 !=1 & V1 != 0 & V2 !=1 & V2 != 0)


BiCopKDE(U[,1], U[,2], type = "contour")

```

(a) Nuage de points avec $V1, V2$ (b) Nuage de points avec $X1, X2$



(a) Densité d'une copule



(b) Estimateur non paramétrique




FIGURE 5